

INSTRUÇÕES GERAIS

- Antes de enviar o seu trabalho, considere com atenção e cuidado as instruções aqui contidas. Não segui-las pode levar o grupo a receber o conceito mínimo (zero).
- O trabalho deverá ser realizado em **quatro ou cinco** alunos (não serão aceitos trabalhos individuais ou em grupos fora das especificações). Não deve haver troca de informações entre grupos distintos. Trabalhos iguais, conceito zero para ambos os grupos.
- A entrega do trabalho será feita via Moodle por meio de link, que será disponibilizado conforme prazos determinados no final destas instruções. Caso seja necessário mais espaço para submissão deverá ser hospedado no github de algum dos membros para baixar os arquivos.
- Os envios devem ser realizados até a data e horário limite estabelecidos para consideração do trabalho. Entregas com atraso de 5 minutos até 24 horas serão considerados com peso de 50%. Não serão aceitas entregas com atraso superior a 24 horas.

DESCRIÇÃO

Este roteiro apresenta detalhes do projeto para a disciplina com foco em algoritmos não supervisionados, aplicados aos dados públicos de diferentes domínios de aplicação.

Os projetos devem contemplar a dataset, análise exploratória, pré-processamento e limpeza de dados, aplicação de técnicas não supervisionadas (K-Means, Hierárquico, DBSCAN, Regras de Associação, etc), visualização e interpretação dos algoritmos, discussões e conclusões.

Cada equipe deverá escolher **um único tema** para desenvolvimento do projeto. A busca pelos datasets para pesquisa é de responsabilidade das equipes.

O objetivo do projeto é integrar conceitos de mineração de dados, análise exploratória, medidas de similaridade/dissimilaridade e aprendizado não supervisionado na resolução de problemas reais.

TEMAS

Tema 1 – Comportamento Digital e Redes Sociais

Dados: Twitter, Reddit, YouTube, etc.

Aplicações:

- clustering de usuários

- padrões de interação
- detecção de bots (anomalias)
- recomendação de conteúdo

Tema 2 – Mobilidade Urbana Inteligente

Dados: Uber, transporte público, GPS, Waze (ou dados simulados)

Aplicações:

- clustering de regiões
- padrões de deslocamento
- detecção de tráfego anômalo
- recomendação de rotas

Tema 3 – Saúde Digital e Wearables

Dados: atividade física, sono, hábitos

Aplicações:

- clusters de estilo de vida
- padrões de saúde
- detecção de comportamentos de risco
- recomendação de hábitos

Tema 4 – Plataformas de Streaming (Netflix/Spotify)

Dados: MovieLens, Spotify

Aplicações:

- clustering de usuários
- padrões de consumo

Tema 5 – E-commerce e comportamento de compra

Dados: Olist (Brasil), Instacart

Aplicações:

- segmentação de clientes
- regras de associação
- detecção de fraude

Tema 6 – Segurança e Anomalias em Sistemas

Dados: logs de rede, acessos

Aplicações:

- clustering de comportamento
- detecção de intrusão
- padrões de acesso

Tema 7 – “Economia de Apps (iFood, Uber, Airbnb)”

Dados: datasets de delivery, corridas, hospedagem

Aplicações:

- clustering de usuários (consumidores vs. entregadores)
- padrões de consumo (horários, regiões)
- detecção de comportamento anômalo (fraudes, cancelamentos)

- recomendação de restaurantes/serviços

Tema 8 – “Finanças Pessoais e Pix”

Dados: transações financeiras simuladas ou abertas

Aplicações:

- clustering de perfis financeiros
- padrões de gasto
- detecção de fraudes (anomalias)
- recomendação de economia/planejamento

Tema 9 – “Jogos Online e Comportamento de Jogadores”

Dados: logs de jogos (Kaggle ou simulados)

Aplicações:

- clustering de jogadores (casual vs. competitivo)
- padrões de gameplay
- detecção de cheaters (anomalias)
- recomendação de matchmaking

Tema 10 – “Educação Online (EAD, MOOCs)”

Dados: interações em plataformas educacionais

Aplicações:

- clustering de estudantes
- padrões de aprendizado
- detecção de evasão (anomalias)
- recomendação de trilhas de estudo

Tema 11 – “Consumo de Energia e Sustentabilidade”

Dados: consumo elétrico residencial (smart meters)

Aplicações:

- clustering de perfis de consumo
- padrões de uso
- detecção de desperdício/anomalias
- recomendação de economia

Tema 12 – “Smart Cities e IoT”

Dados: sensores urbanos (trânsito, poluição, clima)

Aplicações:

- clustering de regiões
- padrões ambientais
- detecção de eventos anômalos
- recomendação de ações urbanas

Tema 13 – “Mercado de Trabalho e LinkedIn-like”

Dados: vagas, habilidades, perfis profissionais

Aplicações:

- clustering de perfis profissionais
- padrões de carreira

- detecção de perfis fora do padrão
- recomendação de vagas

Tema 14 – “Fake News e Informação Online”

Dados: notícias, posts, interações

Aplicações:

- clustering de conteúdos
- padrões de disseminação
- detecção de anomalias (fake news)
- recomendação de conteúdo confiável

DESENVOLVIMENTO

1º ETAPA

Coleta de Dados

- Baixar datasets em formato CSV/JSON.
- Verificar se há valores faltantes e se a base é representativa.
- Realizar a limpeza

Pré-processamento

- Normalização e padronização dos dados: StandardScaler vs MinMaxScaler
- Transformações
- Tratamento de atributos
- Remoção de outliers (se necessário).

2º ETAPA

Análise Exploratória (EDA)

- Estatísticas descritivas, matriz de correlação (pearson/spearman), histogramas, boxplots.
- Identificar variáveis altamente correlacionadas; reduzir redundância (feature selection ou PCA preliminar).
- Sugestões: PCA para variância explicada, ou t-SNE ou UMAP para visualização 2D/3D.
- Análise de impacto na proximidade

3º ETAPA

Aplicação de Algoritmos

- Escolha da métrica em similaridade e dissimilaridade: Euclidiana, Manhattan e Cosine
- Testar diferentes métodos de clusterização.
- Avaliar métricas de coesão e separação (ex.: silhouette score, K por Elbow, Silhouette Score, Davies-Bouldin, Calinski-Harabasz).
- Testar estabilidade: rodar K-Means com várias sementes (ex.: seeds = [0,1,2,42,100]) e comparar ARI/normalizado mutual info entre execuções; ou usar bootstrap.
- Técnicos: silhouette ≥ 0.25 como referência inicial (depende do problema); estabilidade de clusters (ARI entre runs > 0.8 ideal).

4º ETAPA

Padrões Frequentes

- Mineração de Padrões Frequentes

- Apriori ou FP-Growth

Deteção de Anomalias

- distância (outliers)

Interpretação e Conclusões

- Descrever os padrões observados.
- Relacionar os clusters com possíveis explicações.
- Discutir implicações e limitações dos dados.
- O grupo deve justificar: escolha das métricas, escolha dos algoritmos, escolha do número de clusters e escolha das variáveis.

Apresentação dos Resultados

- Slides e Relatório técnico (6 páginas)
- Visualizações com matplotlib, seaborn, ou plotly

ENTREGAS

Entrega Inicial:

- Um integrante do Grupo deverá acessar a planilha no link abaixo para preencher o tema escolhido e Nomes dos integrantes: Apenas quatro ou cinco alunos (não serão aceitos trabalhos individuais ou em grupos fora das especificações).
- **IMPORTANTE:** Não serão aceitos temas iguais. Por isso, defina o quanto antes os grupos e coloque na planilha.
- https://ufubr-my.sharepoint.com/:x/g/personal/marcelo_nascimento_ufu_br/IQDTsvaa4vPWQrQpUwKLtVZHAeXn0UKheialeR9DjqsLJmo?e=9g0tjO

Data da Entrega: 14/05/2026 (Qui) até 23:59.

1ª Entrega: ETAPA 1

No repositório **GitHub**, de um dos membros do grupo, deve ser inseridos:

- Notebook Jupyter (ou .py modular) com os processos do pipeline.
- Código e dados;
- README com nome dos integrantes e um roteiro de como reproduzir as etapas entregues.
- Vídeo curto (5 min) demonstrando: (Tema escolhido, motivação, problema, dataset, quantidade de amostras, atributos principais, problemas encontrados, pré-processamento realizado (normalização, limpeza, transformações), justificativas em relação as técnicas (normalização, por que MinMaxScaler ou StandardScaler?).

No Moodle: Enviar um arquivo com o link do repositório com os dados desta entrega.

IMPORTANTE: Os grupos que **não enviarem a 1ª entrega até a data limite**, não terão direito de fazer as próximas entregas e a avaliação do mesmo, obtendo conceito zero no trabalho.

Data da Entrega: 28/05/2026 (Qui) até 23:59.

2ª Entrega: ETAPA 2

No repositório **GitHub**, de um dos membros do grupo, deve ser inserido:

- Notebook Jupyter (ou .py modular) com os processos do pipeline.
- Código e dados;

- README com nome dos integrantes e um roteiro de como reproduzir as etapas entregues.
- Vídeo curto (5 min) demonstrando: Estatísticas principais, correlação, variáveis relevantes, visualizações (histogramas, bloxplots), PCA/t-SNE/UMAP, similaridade/dissimilaridade, impacto da normalização. Discussões (padrões preliminares foram observados).

No Moodle: Enviar um arquivo com o link do repositório com os dados desta entrega.

IMPORTANTE: Os grupos que **não enviarem a 2ª entrega até a data limite**, não terão direito de fazer as próximas entregas e a avaliação do mesmo, obtendo conceito zero no trabalho.

Data da Entrega: 15/06/2026 (Seg) até 23:59.

3ª Entrega: ETAPA 3

No repositório **GitHub**, de um dos membros do grupo, deve ser inseridos:

- Notebook Jupyter (ou .py modular) com os processos do pipeline.
- Código e dados;
- README com nome dos integrantes e um roteiro de como reproduzir as etapas entregues.
- Vídeo curto (5 min) demonstrando: Algoritmos escolhidos (k-Means Hierárquico, DBSCAN), justificativa, visualização dos clusters, interpretação, métricas (silhouette, Davies-Bouldin, estabilidade), comparações (diferentes Ks, diferentes métricas).

No Moodle: Enviar um arquivo com o link do repositório com os dados desta entrega.

IMPORTANTE: Os grupos que **não enviarem a 3ª entrega até a data limite**, não terão direito de fazer as próximas entregas e a avaliação do mesmo, obtendo conceito zero no trabalho

Data da Entrega: 25/06/2026 (Qui) até 23:59.

4ª Entrega: ETAPA 4

No repositório **GitHub**, de um dos membros do grupo, deve ser inseridos:

- Notebook Jupyter (ou .py modular) com os processos do pipeline.
- Código e dados;
- README com nome dos integrantes e um roteiro de como reproduzir as etapas entregues.

No Moodle:

- **Relatório técnico (PDF, 6 páginas)** com: introdução, descrição dos dados, metodologia, resultados (tabelas, gráficos, mapas), discussão e conclusões.
- **Apresentação (slides)** destacando método, principais achados e limitações.

Data da Entrega: 09/07/2026 (Qui) até 23:59.

Apresentação:

- Serão **alocados 10 minutos para apresentação** junto ao professor.
- Apresentações ocorrerão entre os dias **23/07 (Qui) e 27/07 (Seg)**.