

UNIVERSIDADE FEDERAL DE UBERLÂNDIA
SISTEMAS DE INFORMAÇÃO



FELIPE DUARTE RODRIGUES
GABRIEL AUGUSTO PAIVA
JOÃO PEDRO ZANETTI
MARCOS ANTONIO DA SILVA JUNIOR
MARCELO GABRIEL MILANI SANTOS

ANÁLISE NÃO SUPERVISIONADA DE CONTEÚDOS
BRASILEIROS DE CHECAGEM DE FATOS

UBERLÂNDIA

2026

1 - INTRODUÇÃO

A disseminação de desinformação em ambientes digitais tornou-se um problema relevante para a sociedade contemporânea, especialmente em contextos nos quais notícias, postagens e conteúdos multimídia circulam em larga escala por redes sociais, aplicativos de mensagem e plataformas online. No Brasil, esse fenômeno tem sido observado de forma intensa em temas como política, saúde pública, eleições e pandemia, exigindo iniciativas capazes de monitorar, verificar e compreender os padrões associados à circulação de informações falsas ou enganosas.

Nesse contexto, agências de checagem de fatos exercem papel fundamental ao produzir registros estruturados sobre conteúdos verificados, seus respectivos vereditos e os temas aos quais estão associados. Este trabalho utiliza o dataset *FactCenter*, apresentado no artigo *A Comprehensive Dataset of Brazilian Fact-Checking Stories*, que reúne checagens de fatos publicadas por seis agências brasileiras: *Agência Lupa*, *Aos Fatos*, *Boatos.org*, *Comprova*, *Estadão Verifica* e *Fato ou Fake*. A versão original do conjunto contém 11.647 instâncias publicadas entre julho de 2013 e maio de 2021, abrangendo diferentes tópicos e domínios, como COVID-19, eleições, saúde e política.

O objetivo deste projeto é analisar conteúdos brasileiros de fact-checking por meio de técnicas de aprendizado não supervisionado, buscando identificar padrões estruturais, temáticos e semânticos sem utilizar os rótulos de veredito como variável-alvo de treinamento. Para isso, foram realizadas etapas de limpeza e pré-processamento textual, geração de embeddings semânticos, análise exploratória de dados, aplicação de algoritmos de clusterização, mineração de padrões frequentes e detecção de anomalias. Essa abordagem permite investigar não apenas se os conteúdos se agrupam de acordo com classes como falso, enganoso ou verdadeiro, mas também se existem sinais mais fortes associados a agência de origem, tema, período de publicação ou estilo editorial.

A análise desenvolvida busca, portanto, responder à seguinte questão orientadora: quais padrões podem ser identificados, de forma não supervisionada, em uma base brasileira de checagens de fatos? Ao longo do relatório, os resultados mostram que a estrutura do *FactCenter* é fortemente influenciada pelo desbalanceamento dos vereditos, pela predominância de determinadas agências e por eventos temporais marcantes, como eleições e pandemia. Assim, mais do que separar automaticamente

conteúdos por veracidade, o estudo evidencia como técnicas não supervisionadas podem revelar camadas de organização escondidas no corpus, funcionando como pequenas lanternas estatísticas em uma biblioteca barulhenta de boatos, checagens e disputas de contexto.

2 - DESCRIÇÃO DOS DADOS

O conjunto de dados utilizado neste trabalho foi o *FactCenter*, disponibilizado pelos autores do artigo *A Comprehensive Dataset of Brazilian Fact-Checking Stories*. A base reúne instâncias brasileiras de checagem de fatos publicadas por seis agências: *Agência Lupa*, *Aos Fatos*, *Boatos.org*, *Comprova*, *Estadão Verifica* e *Fato ou Fake*. No dataset original, são disponibilizadas 11.647 checagens, publicadas entre julho de 2013 e maio de 2021, com atributos como URL, agência de origem, título, subtítulo, data de publicação, corpo textual, autores, categorias, tags e vereditos.

Após o carregamento do arquivo *central_de_fatos.csv*, foram realizados procedimentos de limpeza e padronização. Registros sem informações essenciais, como título, texto ou autor, foram removidos, resultando em 11.539 documentos válidos para análise. Também foram convertidas colunas originalmente serializadas como listas, como *authors*, *categories*, *tags* e *rating*, permitindo o uso estruturado desses atributos nas etapas seguintes.

Como cada agência utiliza um vocabulário próprio para classificar as checagens, foi necessário normalizar os vereditos originais em quatro classes canônicas: *falso*, *enganoso*, *verdadeiro* e *inconclusivo*. Essa consolidação permitiu comparar registros de diferentes fontes sob uma taxonomia comum, mesmo preservando a consciência de que as agências possuem critérios editoriais distintos. A distribuição resultante é fortemente desbalanceada: a classe falso concentra 10.142 registros, correspondendo a 87,9% da base; enganoso representa 9,8%; verdadeiro, 1,8%; e inconclusivo, 0,6%. Essa distribuição é apresentada na *Figura A1* e constitui uma das principais características do conjunto de dados.

A distribuição por agência também revela assimetrias importantes. A *Boatos.org* concentra 5.519 registros, ou 47,8% da base, e todos esses registros foram normalizados como falso. Já agências como *Comprova* e *Estadão Verifica* apresentam proporção mais elevada de conteúdos enganosos, indicando critérios de classificação mais granulares para casos em

que há distorção, contexto incompleto ou uso manipulado de informações reais. Esse comportamento, sintetizado na *Figura A2*, indica que a agência de origem não é apenas um metadado descritivo, mas uma variável capaz de influenciar diretamente os padrões encontrados pelos algoritmos.

Do ponto de vista temporal, o dataset cobre aproximadamente oito anos de atividade de *fact-checking* no Brasil. A série histórica evidencia crescimento do volume de checagens ao longo do tempo, com destaque para os anos de 2018, associado ao contexto eleitoral, e 2020, marcado pela pandemia de COVID-19. A evolução temporal apresentada na *Figura A3* reforça que o corpus não é homogêneo ao longo dos anos: ele é atravessado por eventos sociais e políticos que alteram tanto o volume de publicações quanto a composição temática das checagens.

3 - METODOLOGIA

A metodologia adotada foi organizada como um pipeline sequencial, contemplando preparação dos dados, representação semântica dos textos, análise exploratória, aplicação de algoritmos não supervisionados, mineração de padrões frequentes e detecção de anomalias. O objetivo foi investigar a estrutura interna do dataset sem utilizar os vereditos como variável-alvo de treinamento, reservando-os principalmente para interpretação e avaliação posterior dos agrupamentos.

Inicialmente, o arquivo *central_de_fatos.csv* foi carregado e submetido a uma etapa de limpeza. Foram removidos registros sem campos essenciais, como título, corpo textual ou autoria, e foram convertidas colunas serializadas como listas, incluindo *authors*, *categories*, *tags* e *rating*. Em seguida, os vereditos originais, que variavam conforme a terminologia de cada agência, foram agrupados em quatro classes canônicas: falso, enganoso, verdadeiro e inconclusivo. Essa normalização foi necessária para permitir análises comparáveis entre diferentes fontes.

Para representar semanticamente os documentos, foi utilizada uma estratégia baseada em *embeddings*. Cada registro foi transformado em um texto composto pelo título repetido duas vezes e pelos primeiros 1800 caracteres do corpo da checagem. A repetição do título teve como objetivo aumentar o peso do enunciado principal da verificação, uma vez que os títulos geralmente concentram o conteúdo checado e, em muitos casos, o próprio indício do veredito. Antes da geração dos vetores, foram removidos *URLs*, caracteres

não alfabéticos e espaços excedentes, preservando acentos da língua portuguesa.

Os *embeddings* foram gerados com o modelo *rufimelo/bert-large-portuguese-cased-sts*, especializado em similaridade semântica para português brasileiro, com saída de 1024 dimensões. Como essa dimensionalidade é elevada para algoritmos baseados em distância, aplicou-se *PCA* para redução dimensional, mantendo 95% da variância explicada, o que resultou em 424 componentes. Além disso, foi aplicada a técnica *UMAP* para projeção bidimensional dos *embeddings*, com métrica cosseno, permitindo a visualização da organização semântica dos documentos. A projeção *UMAP* utilizada para inspeção visual dos dados é apresentada na *Figura A4*.

A etapa de análise exploratória incluiu estatísticas descritivas, distribuição dos vereditos, análise por agência, evolução temporal, análise de categorias, matriz de correlação entre atributos numéricos derivados e avaliação de similaridade e dissimilaridade entre classes. Também foi avaliado o impacto de diferentes estratégias de normalização sobre as distâncias, com o objetivo de definir representações mais adequadas para os algoritmos posteriores. Para métodos baseados em distância euclidiana, como *K-Means* e agrupamento hierárquico, utilizou-se *StandardScaler*; para métodos com distância cosseno, como *DBSCAN*, considerou-se a normalização *L2*.

Na etapa de clusterização, foram avaliados três algoritmos: *K-Means*, agrupamento hierárquico e *DBSCAN*. O *K-Means* foi utilizado como baseline por ser um método clássico de particionamento, com avaliação de diferentes valores de *K*, método do cotovelo, *Silhouette Score* e estabilidade entre diferentes sementes. O agrupamento hierárquico foi avaliado com diferentes critérios de ligação, com ênfase no método *Ward*. O *DBSCAN* foi utilizado por permitir a identificação de regiões densas e pontos classificados como ruído, sem exigir previamente o número de *clusters*. As métricas utilizadas foram *Silhouette Score*, *Davies-Bouldin*, *Calinski-Harabasz*, *ARI* e *NMI*, além da análise qualitativa da composição dos *clusters* por veredito, agência e palavras representativas. A comparação geral dos algoritmos é apresentada na *Figura A5*.

Para a mineração de padrões frequentes, cada registro foi convertido em uma transação composta por quatro grupos de itens: agência, veredito normalizado, categoria temática e período temporal. As categorias foram normalizadas em grupos semânticos mais amplos, reduzindo a dispersão dos rótulos originais.

Sobre essa matriz transacional, foram aplicados os algoritmos *FP-Growth* e *Apriori*, com suporte mínimo de 0,05. Em seguida, foram extraídas regras de associação com confiança mínima de 0,5 e *lift* mínimo de 1,0, permitindo identificar relações recorrentes entre agência, categoria, período e veredito. Os resultados dessa etapa são sintetizados na *Figura A6*.

Por fim, a detecção de anomalias foi realizada sobre o espaço vetorial reduzido por *PCA*. Foram utilizados dois métodos complementares: *Isolation Forest*, voltado à identificação de pontos globalmente isolados, e *Local Outlier Factor (LOF)*, que detecta pontos localmente atípicos em relação à vizinhança. A análise considerou tanto os resultados individuais de cada algoritmo quanto o consenso entre ambos, de modo a destacar registros semanticamente incomuns com maior robustez. O perfil das anomalias detectadas é apresentado na *Figura A7*.

4 - RESULTADOS

A análise exploratória confirmou que o *FactCenter* apresenta forte desbalanceamento de classes e influência significativa da agência de origem. Após a limpeza, a classe falso concentrou 87,9% dos registros, enquanto enganoso, verdadeiro e inconclusivo representaram, respectivamente, 9,8%, 1,8% e 0,6% da base. A distribuição por agência também se mostrou assimétrica: a *Boatos.org* respondeu por 47,8% dos documentos e todos os seus registros foram mapeados para falso. Esse comportamento, ilustrado nas *Figuras A1 e A2*, indica que a estrutura do dataset não depende apenas do conteúdo semântico das checagens, mas também dos critérios editoriais adotados por cada fonte.

A análise temporal mostrou crescimento expressivo no volume de checagens ao longo dos anos, com destaque para 2018, associado ao período eleitoral, e 2020, associado à pandemia de COVID-19. O ano de 2020 concentrou o maior número de registros, reforçando o impacto de eventos sociais e sanitários sobre a produção de conteúdo de *fact-checking*. Além disso, observou-se aumento relativo da classe enganoso nos anos mais recentes, sugerindo maior presença de conteúdos que não são inteiramente falsos, mas que manipulam contexto, interpretação ou atribuição de fatos. Essa evolução é apresentada na *Figura A3*.

A análise das categorias mostrou predominância de temas como política, saúde, Brasil, mundo, tecnologia e redes sociais. Entretanto, a distribuição temática também revelou inconsistências

nos esquemas de categorização das agências. Algumas categorias apresentaram alta pureza em falso, mas esse padrão esteve fortemente associado à predominância da *Boatos.org*, e não necessariamente a uma propriedade semântica da categoria. Por outro lado, categorias como pandemia, eleições e políticas públicas apresentaram maior diversidade de vereditos, indicando maior riqueza analítica para interpretação dos agrupamentos e das regras de associação.

No espaço vetorial, a representação baseada em *embeddings BERT* e *PCA* permitiu avaliar a organização semântica dos documentos. A análise de similaridade mostrou que as distâncias intra-classe foram, em média, menores que as distâncias inter-classe, indicando que os *embeddings* capturaram algum grau de proximidade semântica entre documentos de mesmo veredito. No entanto, as diferenças absolutas foram pequenas, o que antecipa a dificuldade de obter agrupamentos bem separados por veracidade. A projeção *UMAP*, apresentada na *Figura A4*, reforça essa interpretação: os documentos exibem regiões de concentração, mas sem separação nítida entre falso, enganoso e verdadeiro.

Na etapa de clusterização, os três algoritmos avaliados apresentaram comportamentos complementares. O *K-Means* foi testado com diferentes valores de *K*, mas o método do cotovelo não indicou uma separação clara. Com *K=6*, escolhido por corresponder ao número de agências, o algoritmo obteve *Silhouette* de -0,0085 e *ARI* de 0,0442 em relação aos vereditos, indicando baixa correspondência entre clusters e classes reais. Ainda assim, a análise qualitativa dos *clusters* revelou padrões interpretáveis: um grupo associado a *fact-checking* jornalístico mais nuançado, com maior presença de *Lupa* e *Aos Fatos*; um grupo associado à COVID-19, com termos como covid e vacina; e grupos fortemente marcados pelo padrão textual da *Boatos.org*.

O agrupamento hierárquico com *Ward* apresentou as melhores métricas internas, especialmente com *K=2*, alcançando *Silhouette* de 0,1158 e *Davies-Bouldin* de 1,8119. Apesar disso, o *ARI* em relação aos vereditos permaneceu próximo de zero, indicando que a divisão geométrica encontrada não corresponde diretamente às classes falso, enganoso ou verdadeiro. Já o *DBSCAN* identificou quatro *clusters* densos, mas classificou 62,4% dos pontos como ruído, com *Silhouette* de 0,0303 e *ARI* negativo em relação aos vereditos. Esse resultado sugere que o *DBSCAN* capturou nichos temáticos específicos, e não uma estrutura geral de veracidade. A comparação entre os algoritmos é sintetizada na *Figura A5* e na Tabela T1.

Na mineração de padrões frequentes, cada documento foi tratado como uma transação composta por agência, categoria, período e veredito. Os algoritmos *FP-Growth* e *Apriori* produziram os mesmos 69 itemsets frequentes, o que confirmou a consistência da mineração. Foram geradas 84 regras de associação, das quais todas as regras com consequente de veredito apontaram para *rating=falso*. Esse resultado reflete o forte suporte da classe majoritária e indica que as regras de veredito tendem a reproduzir a distribuição base do dataset, em vez de revelar associações semanticamente novas.

O achado mais relevante das regras de associação não esteve na predição direta do veredito, mas na identificação de especializações editoriais. A regra *categoria=redes_sociais* → *agencia=aos fatos* apresentou confiança de 1,0 e *lift* elevado, indicando que os registros classificados nessa categoria estavam concentrados na agência *Aos Fatos*. Também foram observados padrões associados à *Boatos.org* em categorias como *política*, *Brasil* e *saúde*, todas com forte predominância de *falso*. Esses resultados reforçam que as agências não apenas usam rótulos distintos, mas também cobrem temas diferentes, o que ajuda a explicar os padrões observados nos *clusters*. A *Figura A6* apresenta a síntese visual das regras mineradas.

Por fim, a detecção de anomalias foi realizada com *Isolation Forest* e *Local Outlier Factor*, considerando como mais robustos os casos detectados por ambos os métodos. Foram identificadas 320 anomalias em consenso, com enriquecimento das classes minoritárias: inconclusivo apareceu 4,51 vezes mais entre as anomalias do que seria esperado pela distribuição geral, enquanto verdadeiro apresentou enriquecimento de 1,77 vez. Isso indica que os registros atípicos não correspondem simplesmente a conteúdos falsos, mas a documentos semanticamente incomuns no corpus, frequentemente associados a temas raros, formulações específicas ou casos de verificação menos recorrentes. O perfil das anomalias é apresentado na *Figura A7*.

Em conjunto, os resultados mostram que as técnicas não supervisionadas identificaram padrões relevantes, mas não separaram a base de forma consistente por veracidade. O sinal predominante nos dados está relacionado a uma combinação de tema, período, agência de origem e estilo editorial. Assim, a principal contribuição analítica não foi a criação de *clusters* equivalentes aos vereditos, mas a revelação de estruturas internas do *FactCenter* que ajudam a compreender como a desinformação verificada se

organiza em torno de fontes, eventos e categorias temáticas.

5 - DISCUSSÃO

Os resultados obtidos indicam que a aplicação de técnicas não supervisionadas ao *FactCenter* revela padrões relevantes, mas não produz uma separação direta e robusta entre conteúdos falso, enganoso, verdadeiro e inconclusivo. Esse comportamento não deve ser interpretado apenas como limitação dos algoritmos, mas como reflexo da própria natureza do conjunto de dados. O corpus é altamente desbalanceado, com predominância da classe falso, e possui forte influência da agência de origem, especialmente da *Boatos.org*, que representa quase metade dos registros e classifica todos os seus conteúdos como falsos.

Esse viés de agência afeta diretamente a interpretação dos clusters. Como os textos foram produzidos pelas próprias agências de checagem, os *embeddings* capturam não apenas o conteúdo semântico das notícias verificadas, mas também o estilo textual de cada fonte. Assim, padrões como vocabulário recorrente, estrutura dos títulos, uso de expressões editoriais e temas cobertos acabam tendo peso significativo na formação dos agrupamentos. Por isso, os clusters encontrados refletem mais fortemente diferenças editoriais, temáticas e temporais do que classes de veracidade propriamente ditas. Essa interpretação é reforçada pela baixa correspondência entre os agrupamentos e os vereditos, observada por métricas externas como *ARI* e *NMI*.

Outro ponto importante é que a veracidade de uma informação não é necessariamente separável apenas pela semântica superficial do texto. Conteúdos falsos ou enganosos frequentemente são construídos para parecer plausíveis e podem compartilhar vocabulário, temas e estrutura narrativa com conteúdos verdadeiros sobre o mesmo assunto. Por exemplo, checagens relacionadas à pandemia, eleições ou saúde podem conter termos semelhantes independentemente do veredito final. Dessa forma, um modelo baseado apenas em *embeddings* textuais tende a aproximar documentos pelo assunto tratado, e não pela veracidade atribuída pela agência.

A mineração de padrões frequentes confirma essa leitura. As regras com consequente de veredito apontaram exclusivamente para *rating=falso*, mas com *lift* baixo, indicando que essas associações reproduzem a distribuição majoritária da base, em vez de revelar

uma relação nova e informativa. Em contrapartida, as regras mais relevantes apareceram na relação entre categorias e agências, como no caso da concentração da categoria *redes_sociais* na *Aos Fatos*. Esse achado demonstra que o dataset possui uma camada importante de especialização editorial: as agências não apenas classificam de forma diferente, mas também cobrem temas diferentes.

A detecção de anomalias também contribui para essa interpretação. Os registros considerados anômalos não representam automaticamente *fake news*, mas documentos semanticamente atípicos em relação ao padrão dominante do corpus. O enriquecimento das classes inconclusivo e verdadeiro entre as anomalias sugere que conteúdos menos frequentes e mais específicos tendem a ocupar regiões menos densas do espaço vetorial. Isso ocorre porque a base é dominada por checagens falsas, especialmente de temas recorrentes e formatos editoriais repetidos. Assim, documentos verdadeiros, inconclusivos ou associados a temas raros podem parecer “ilhas” semânticas em um oceano de boatos recorrentes.

Portanto, a principal contribuição analítica do projeto não está em obter um classificador implícito de veracidade, mas em mostrar os limites e possibilidades da análise não supervisionada nesse domínio. As técnicas aplicadas permitiram identificar estruturas internas do *FactCenter*, como concentração temática, especialização por agência, influência temporal e registros atípicos. Ao mesmo tempo, os resultados indicam que a detecção não supervisionada de desinformação exige mais do que representação textual: seria necessário incorporar metadados, informações de fonte, contexto temporal, sinais de circulação e estratégias para reduzir o viés editorial das agências.

6 - CONCLUSÃO

Este trabalho aplicou técnicas de aprendizado não supervisionado ao dataset *FactCenter* com o objetivo de investigar padrões em conteúdos brasileiros de checagem de fatos. A análise contemplou desde a preparação e representação semântica dos textos até a aplicação de algoritmos de clusterização, mineração de padrões frequentes e detecção de anomalias. De forma geral, os resultados mostram que a estrutura do dataset é fortemente influenciada por três fatores: o desbalanceamento dos vereditos, a agência de origem e os eventos temporais que marcaram o período analisado.

A principal conclusão é que os *embeddings* textuais, embora úteis para capturar similaridade semântica entre documentos, não foram suficientes para separar os registros de forma consistente segundo as classes de veredito. Os algoritmos de clusterização revelaram grupos associados a temas, períodos e estilos editoriais, mas apresentaram baixa correspondência com rótulos como falso, enganoso e verdadeiro. Isso indica que, em bases de *fact-checking*, a veracidade não é uma propriedade facilmente inferida apenas pela proximidade textual, pois conteúdos falsos e verdadeiros sobre o mesmo tema podem compartilhar vocabulário e estrutura narrativa semelhantes.

A mineração de padrões frequentes reforçou essa interpretação. As regras com consequente de veredito apontaram exclusivamente para *rating=falso*, resultado explicado pela predominância dessa classe na base. Entretanto, as regras mais informativas evidenciaram especializações editoriais entre as agências, como a concentração de determinados temas em fontes específicas. Assim, os padrões mais relevantes não descrevem apenas a falsidade dos conteúdos, mas a forma como cada agência organiza, classifica e cobre diferentes tipos de desinformação.

A detecção de anomalias complementou os resultados ao identificar registros semanticamente atípicos. O enriquecimento das classes inconclusivo e verdadeiro entre as anomalias sugere que documentos minoritários, menos recorrentes ou mais específicos tendem a se afastar do padrão dominante do corpus. Esse achado reforça que anomalia, neste contexto, não equivale necessariamente a *fake news*, mas a conteúdos que fogem da concentração temática e editorial predominante.

Como limitações, destacam-se o forte desbalanceamento da base, a heterogeneidade dos critérios de categorização entre agências e o uso de textos produzidos pelas próprias organizações de fact-checking, e não necessariamente dos conteúdos originais que circularam nas redes. Além disso, a representação textual por *embeddings* não incorpora informações externas importantes, como engajamento, plataforma de circulação, autoria original, rede de disseminação ou contexto social. Também há limitações técnicas associadas à alta dimensionalidade dos vetores, que dificulta a formação de clusters compactos e bem separados.

Como trabalhos futuros, recomenda-se combinar os *embeddings* textuais com metadados estruturados, como agência, categoria, data, presença de mídia e informações de circulação. Também seria

interessante realizar análises estratificadas por agência, reduzindo o viés editorial, além de testar representações híbridas e técnicas de redução de dimensionalidade mais agressivas antes da clusterização. Por fim, a incorporação de dados das plataformas onde os conteúdos circularam poderia aproximar a análise do fenômeno real da desinformação, que não depende apenas do texto, mas também de sua difusão, repetição e recepção pelo público.

Em síntese, o projeto mostrou que técnicas não supervisionadas são úteis para explorar grandes

coleções de *fact-checking*, revelar padrões editoriais e identificar documentos atípicos. Contudo, a separação automática de veracidade exige sinais adicionais além do conteúdo textual. O *FactCenter*, mais do que uma base facilmente divisível entre falso e verdadeiro, comporta-se como um mosaico de temas, fontes, períodos e estilos de verificação, no qual a desinformação aparece menos como uma classe isolada e mais como um fenômeno atravessado por contexto.

ANEXOS




Figura A1 - Distribuição dos vereditos de fact-checking.




Figura A2 - Volume de verificações e composição de vereditos por agência.




Figura A3 - Evolução temporal das checagens no FactCenter.




Figura A4 - Projeção UMAP dos embeddings em duas dimensões.




Figura A5 - Comparação dos algoritmos de clusterização.

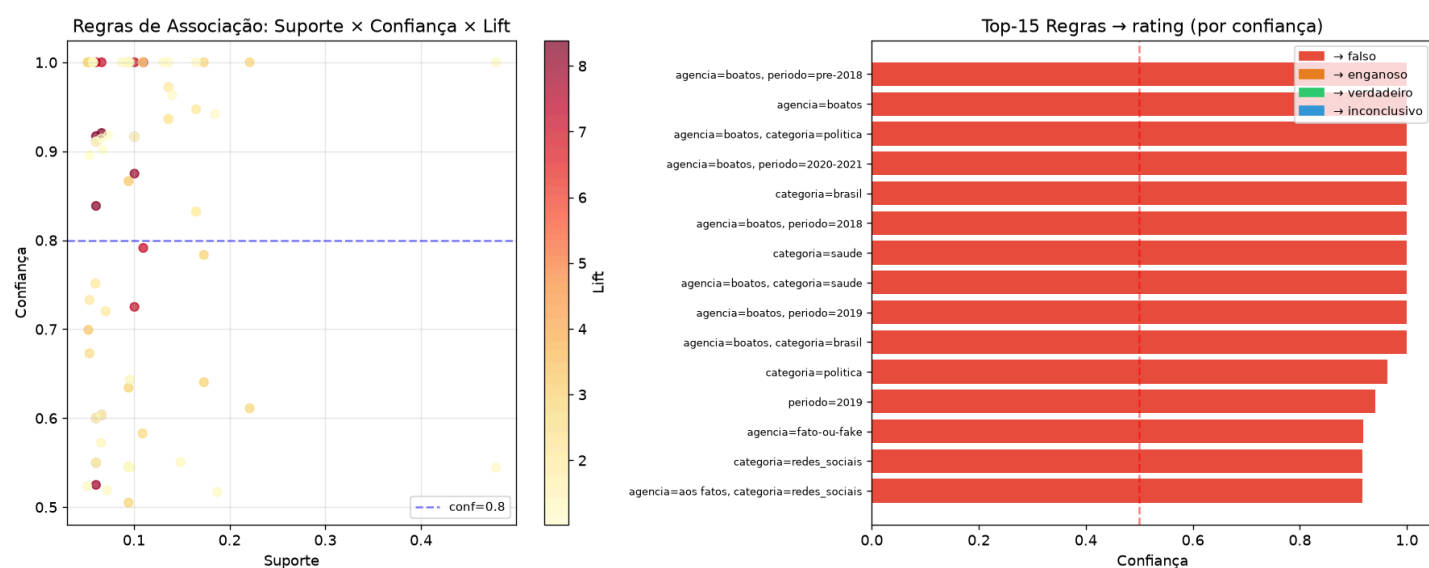


Figura A6 - Regras de associação mineradas.




Figura A7 - Perfil das anomalias detectadas.

Algoritmo	Configuração	Clusters	Silhouette	Davies-Bouldin	ARI	Interpretação
K-Means	K = 6	6	-0,0085	14,5448	0,0442	Captura padrões fracos, temáticos e editoriais
Hierárquico Ward	K = 2	2	0,1158	1,8119	-0,0058	Melhor separação geométrica, sem aderência aos vereditos
DBSCAN	eps = 0,56; min = 20	4	0,0303	2,9829	-0,1210	Detecta nichos densos e muitos pontos como ruído

Tabela T1 - Síntese dos resultados de clusterização